

# Podstawy sztucznej inteligencji AI

część 3

# **Logika rozmyta**

# Wnioskowanie przybliżone

Przyjmijmy, że zdania występujące w regułach **modus ponens** oraz **modus tollens** zawierają **nieprecyzyjne** określenia.

Oznacza to, że zdaniom tym odpowiadają pewne **zbiory rozmyte**.

Rozmyta reguła *modus ponens*

x jest A'	przesłanka
JEŻELI x jest A TO y jest B	implikacja
<hr/>	
y jest B'	wniosek

gdzie:  $A, A' \subseteq X$  i  $B, B' \subseteq Y$  są **zbiorami rozmytymi**

$x, y$  są **zmiennymi lingwistycznymi**

# Przykład

Prędkość samochodu jest duża

przesłanka

Jeżeli prędkość samochodu jest bardzo duża  
to poziom hałasu jest wysoki

implikacja

---

Poziom hałasu w samochodzie jest średniowysoki

wniosek

## Zmienne lingwistyczne

$x$  – prędkość samochodu

Zbiór wartości:  $T_x = \{\text{mała, średnia, duża, bardzo duża}\}$

$y$  – poziom hałasu

Zbiór wartości:  $T_y = \{\text{mały, średni, średniowysoki, wysoki}\}$

## Przykład (cd)

Zbiory rozmyte:

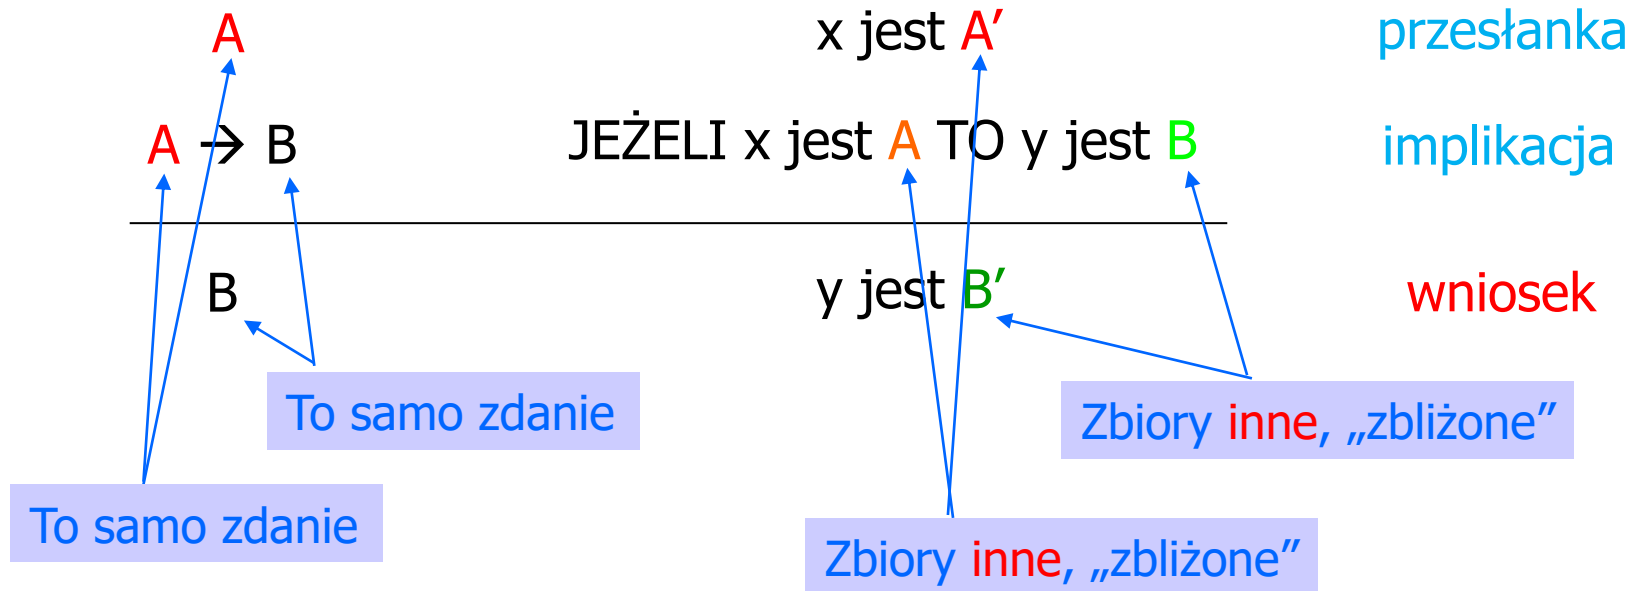
A = "bardzo duża prędkość samochodu"

A' = "duża prędkość samochodu"

B = "wysoki poziom hałasu"

B' = "średniowysoki poziom hałasu"

Jaka jest różnica między nierozmytą i rozmytą regułą *modus ponens*?



Zbiór rozmyty  $B'$  jest **złożeniem** zbioru rozmytego  $A'$  i **rozmytej implikacji**  $A \rightarrow B$ , która jest równoważna pewnej relacji rozmytej  $R \subseteq X \times Y$  czyli

$$B' = A' \circ (A \rightarrow B)$$

Zatem

$$\mu_{B'}(y) = \sup_{x \in X} \{ \mu_{A'}(x) \overset{T}{*} \mu_{A \rightarrow B}(x, y) \}$$

gdzie  $\mu_{A \rightarrow B}(x, y)$  jest funkcją przynależności relacji  $R$ .

Jeżeli  $T(a, b) = \min\{a, b\}$  wówczas

$$\mu_{B'}(y) = \sup_{x \in X} \{ \min\{ \mu_{A'}(x), \mu_{A \rightarrow B}(x, y) \} \}$$

Zauważmy, że jeżeli  $A = A'$  i  $B = B'$  wówczas **rozmyta reguła *modus ponens*** redukuje się do **zwykłej reguły *modus ponens***.

**Jak modelować implikację?**

# Model Mamdaniego

$$\mu_{A \rightarrow B}(x, y) = T(\mu_A(x), \mu_B(y))$$

gdzie **T** jest dowolną *t*-normą.

## Przykład

Reguła typu **minimum**

$$\mu_{A \rightarrow B}(x, y) = \min\{\mu_A(x), \mu_B(y)\}$$

Reguła typu **iloczyn (Larsena)**

$$\mu_{A \rightarrow B}(x, y) = \mu_A(x) \cdot \mu_B(y)$$



Zauważmy, że

$\mu_A(x)$	$\mu_B(y)$	$\min\{\mu_A(x), \mu_B(y)\}$	$\mu_A(x)\mu_B(y)$
0	0	0	0
0	1	0	0
1	0	0	0
1	1	1	1

Wniosek

Reguły typu Mamdaniego **nie są implikacjami w sensie logicznym.**

# Model logiczny

## Definicja

Funkcję  $I: [0,1]^2 \rightarrow [0,1]$  spełniającą następujące warunki:

- 1)  $a_1 \leq a_3 \Rightarrow I(a_1, a_2) \geq I(a_3, a_2)$  dla  $a_1, a_2, a_3 \in [0,1]$
- 2)  $a_2 \leq a_3 \Rightarrow I(a_1, a_2) \leq I(a_1, a_3)$  dla  $a_1, a_2, a_3 \in [0,1]$
- 3)  $I(0, a_2) = 1$  dla  $a_2 \in [0,1]$
- 4)  $I(a_1, 1) = 1$  dla  $a_1 \in [0,1]$
- 5)  $I(1, 0) = 0$

nazywamy **implikacją rozmytą**.

## Przykład

Implikacja binarna  $I(a,b)=\max\{1 - a, b\}$

Implikacja Łukasiewicza  $I(a,b)=\min\{1,1 - a + b\}$

Implikacja Reichenbacha  $I(a,b)=1 - a + a \cdot b$

Implikacja Gödela 
$$I(a,b) = \begin{cases} 1 & \text{dla } a \leq b \\ b & \text{dla } a > b \end{cases}$$

Funkcja  $I$  pozwala nam definiować funkcję przynależności dla implikacji

$$\mu_{A \rightarrow B}(x, y) = I(\mu_A(x), \mu_B(y))$$

(implikacja jest relacją rozmytą  $R \subseteq X \times Y$ )

## Implikacija binarna

$\mu_A(x)$	$\mu_B(y)$	$1-\mu_A(x)$	$\max\{1-\mu_A(x), \mu_B(y)\}$
0	0	1	1
0	1	1	1
1	0	0	0
1	1	0	1

## Implikacija Gödela

$\mu_A(x)$	$\mu_B(y)$	
0	0	1
0	1	1
1	0	0
1	1	1

# Rozmyty system wnioskujący

## PRZYKŁAD

# Problem

Chcemy zbudować przykładowy sterownik rozmyty, który dla otrzymanej na wejściu odległości od przeszkody (**odleglosc**) wyznaczy nam prędkość (**predkosc**) pojazdu.

Wykorzystamy dwie zmienne lingwistyczne:



# Odległość


Zmienna lingwistyczne:

odległość  
(d)



przestrzeń rozważań:  $D = [0, 300]$

Możliwe  
wartości:



# Prędkość


Zmienna lingwistyczne:

prędkość  
(v)



przestrzeń rozważań:  $V = [0, 120]$


Możliwe  
wartości:





# Rozmyty system wnioskujący


Przyjmijmy, że na **wejście sterownika** podana jest pewna wartość odległości  $\bar{d} = 75m$



## Blok rozmywania

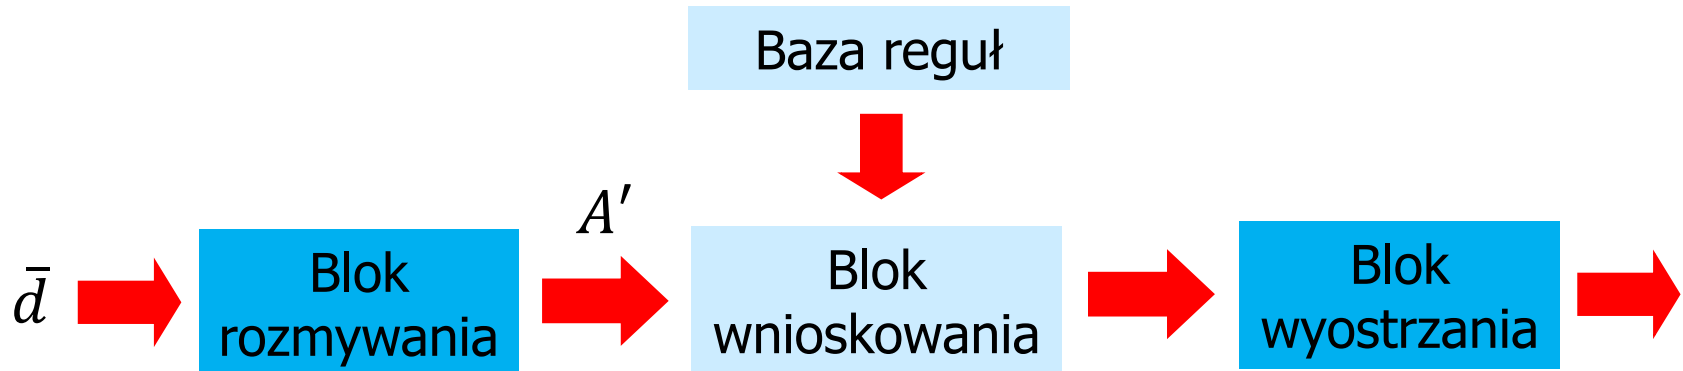
Blok rozmywania wartości otrzymanej na wejściu  $\bar{d} = 75m$  przyporządkowuje zbiór rozmyty  $A'$  zdefiniowany w przestrzeni  $D = [0, 300]$  o następującej funkcji przynależności:

$$\mu_{A'}(d) = \delta(d - \bar{d}) = \begin{cases} 1, & d = \bar{d} \\ 0, & d \neq \bar{d} \end{cases}$$



# Rozmyty system wnioskujący

Przyjmijmy, że na **wejście sterownika** podana jest pewna wartość odległości  $\bar{d} = 75m$



# Baza reguł

Rozważymy następujące reguły:

**R<sub>1</sub>** IF odległość IS mała THEN prędkość IS mała


**R<sub>2</sub>** IF odległość IS średnia THEN prędkość IS średnia

**R<sub>3</sub>** IF odległość IS duża THEN prędkość IS duża

# Reguły

Każda reguła ma postać implikacji:

$R_k$  IF **odległość** IS ..... THEN **prędkość** IS .....

pojęcie rozmyte                      pojęcie rozmyte

Implikację możemy zapisać symbolicznie jako:

$$R_k: A_k \rightarrow B_k$$

gdzie  $A_k \subseteq D = [0,300]$  i  $B_k \subseteq V = [0,120]$  są zbiorami rozmytymi zdefiniowanymi wcześniej.

# Implikacja

Implikację:  $R_k: A_k \rightarrow B_k$

traktujemy jako **relację rozmytą**  $R_k \subseteq D \times V$ .

W **modelu Mamdaniego** funkcja przynależności dla tej relacji jest zdefiniowana następująco:

$$\mu_{A_k \rightarrow B_k}(d, v) = T(\mu_A(d), \mu_B(v))$$

gdzie  $T$  jest operatorem t-normy:

$$T(a, b) = \min\{a, b\}$$

$$T(a, b) = a \cdot b$$

# Blok wnioskowania

Wyjściami bloku wnioskowania są zbiory rozmyte  $\bar{B}_k$  będące **złożeniami** zbioru  $A'$  (wyjście bloku rozmywania) z **każdą regułą**  $R_k$  traktowaną jako relacja rozmyta:

$$\mu_{\bar{B}_k}(v) = \sup_{d \in D} \{T(\mu_{A'}(d), \mu_{R_k}(d, v))\}$$

gdzie  $T$  jest operatorem t-normy.

W naszym przykładzie przyjmijmy, że:

$$T(a, b) = \min\{a, b\}$$

W ten sam sposób zdefiniujemy t-normę w [implikacji](#).

## Blok wnioskowania

Otrzymujemy zatem:

$$\mu_{\bar{B}_k}(v) = \sup_{d \in D} \{T(\mu_{A'}(d), \mu_{R_k}(d, v))\} =$$

$$= \sup_{d \in D} \{\min\{\mu_{A'}(d), \mu_{R_k}(d, v)\}\} =$$

Korzystamy teraz z definicji zbioru  $A'$ :  $\mu_{A'}(d) = \begin{cases} 1, & d = \bar{d} \\ 0, & d \neq \bar{d} \end{cases}$

$$= \min\{1, \mu_{R_k}(\bar{d}, v)\} =$$

Korzystamy z definicji implikacji w modelu Mamdaniego:

$$= \min\{1, \min\{\mu_{A_k}(\bar{d}), \mu_{B_k}(v)\}\} = \min\{\mu_{A_k}(\bar{d}), \mu_{B_k}(v)\}$$



## Blok wnioskowania

Czyli zbiór na wyjściu bloku wnioskowania ma następującą funkcję przynależności:

$$\mu_{\bar{B}_k}(v) = \min\{\mu_{A_k}(\bar{d}), \mu_{B_k}(v)\}$$

gdzie  $k = 1, 2, 3$  bo tyle mamy reguł w bazie.

Spróbujmy skorzystać z tej formuły i znaleźć zbiory  $\bar{B}_k$ .

W tym celu wykorzystamy funkcje przynależności do zbiorów reprezentujących określenia rozmyte z reguł:

$$\mathbf{R}_k: A_k \rightarrow B_k$$


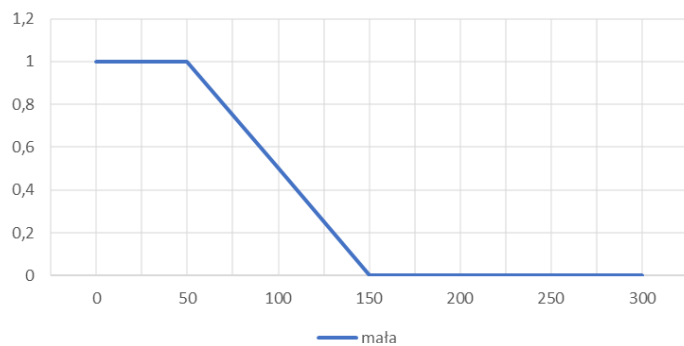
# Blok wnioskowania

$$\mu_{\bar{B}_k}(v) = \min\{\mu_{A_k}(\bar{d}), \mu_{B_k}(v)\}$$



$A_k$

$B_k$


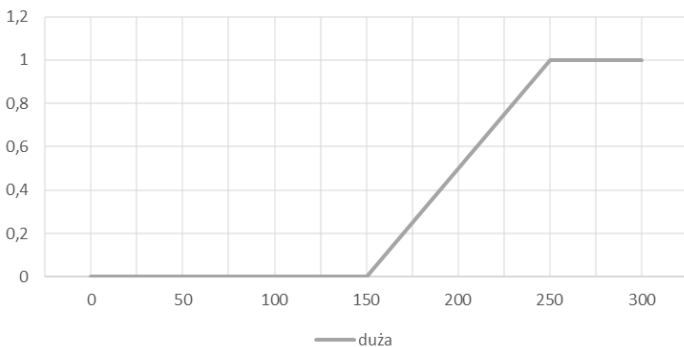
$R_1$



$R_2$



$R_3$




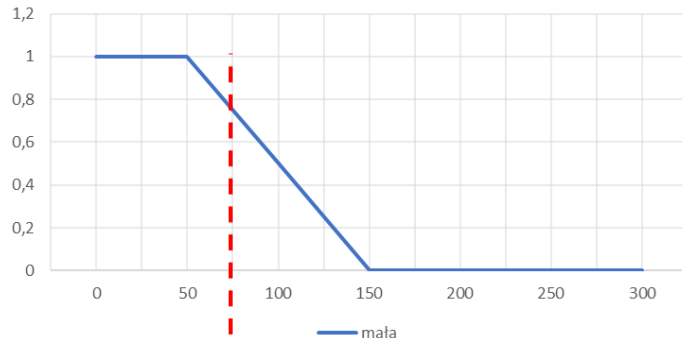
# Blok wnioskowania

$$\mu_{\bar{B}_k}(v) = \min\{\mu_{A_k}(\bar{d}), \mu_{B_k}(v)\}$$


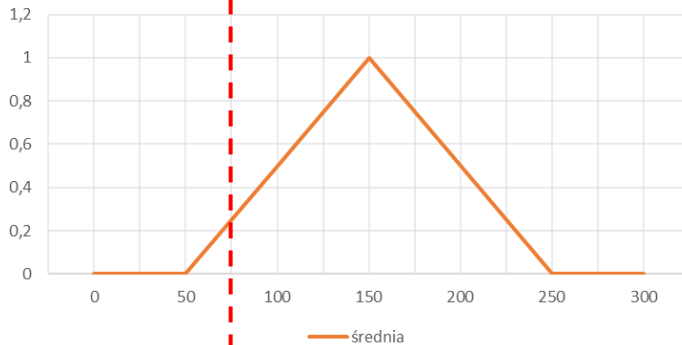
$A_k$

$B_k$



$R_1$



$R_2$



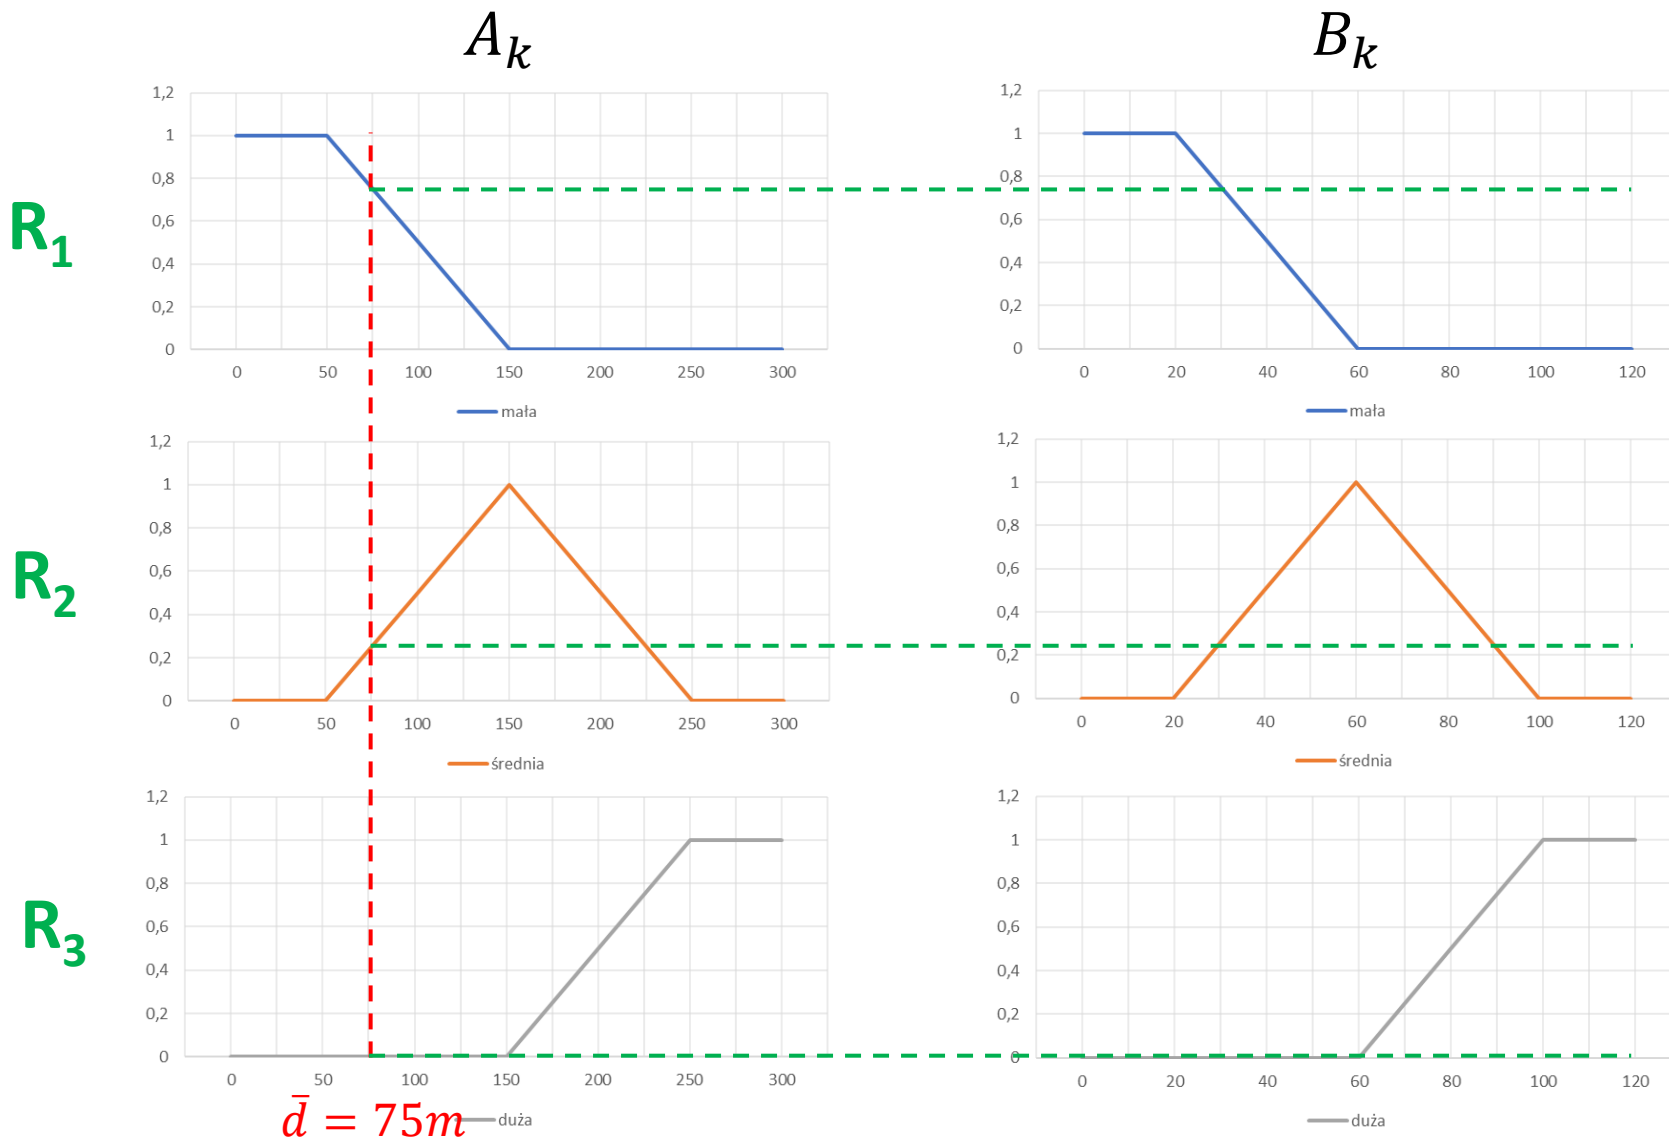
$R_3$



$\bar{d} = 75m$  — duża

# Blok wnioskowania

$$\mu_{\bar{B}_k}(v) = \min\{\mu_{A_k}(\bar{d}), \mu_{B_k}(v)\}$$




# Blok wnioskowania

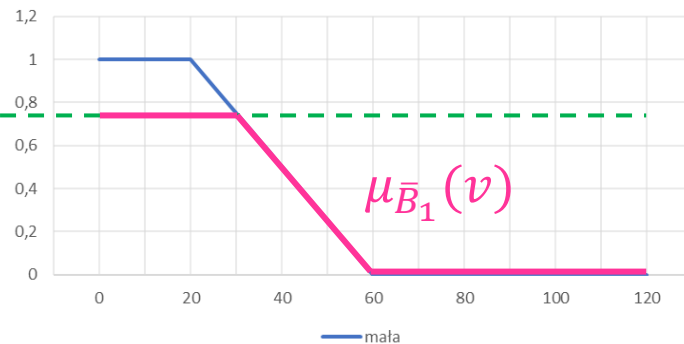
$$\mu_{\bar{B}_k}(v) = \min\{\mu_{A_k}(\bar{d}), \mu_{B_k}(v)\}$$

$R_1$

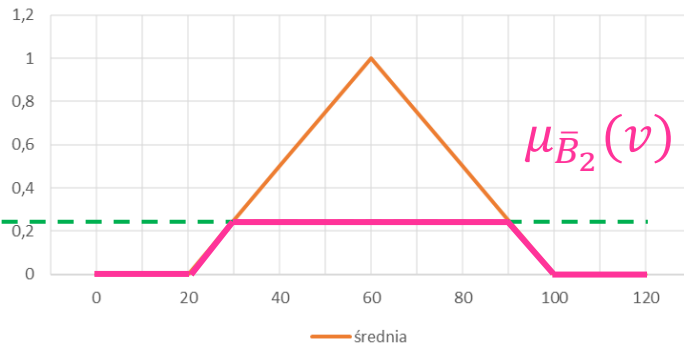
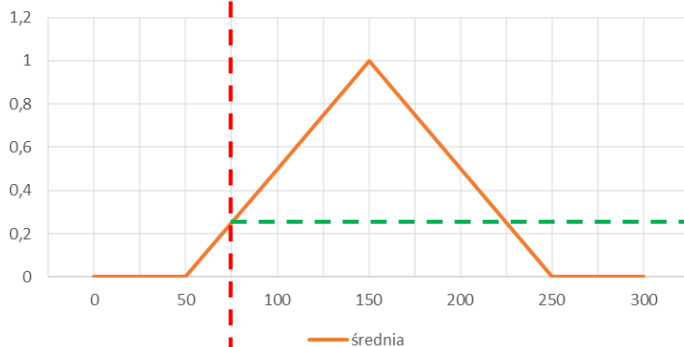
$A_k$



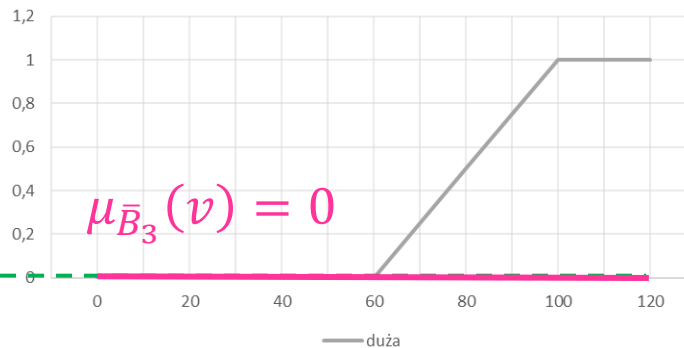

$B_k$



$R_2$



$R_3$

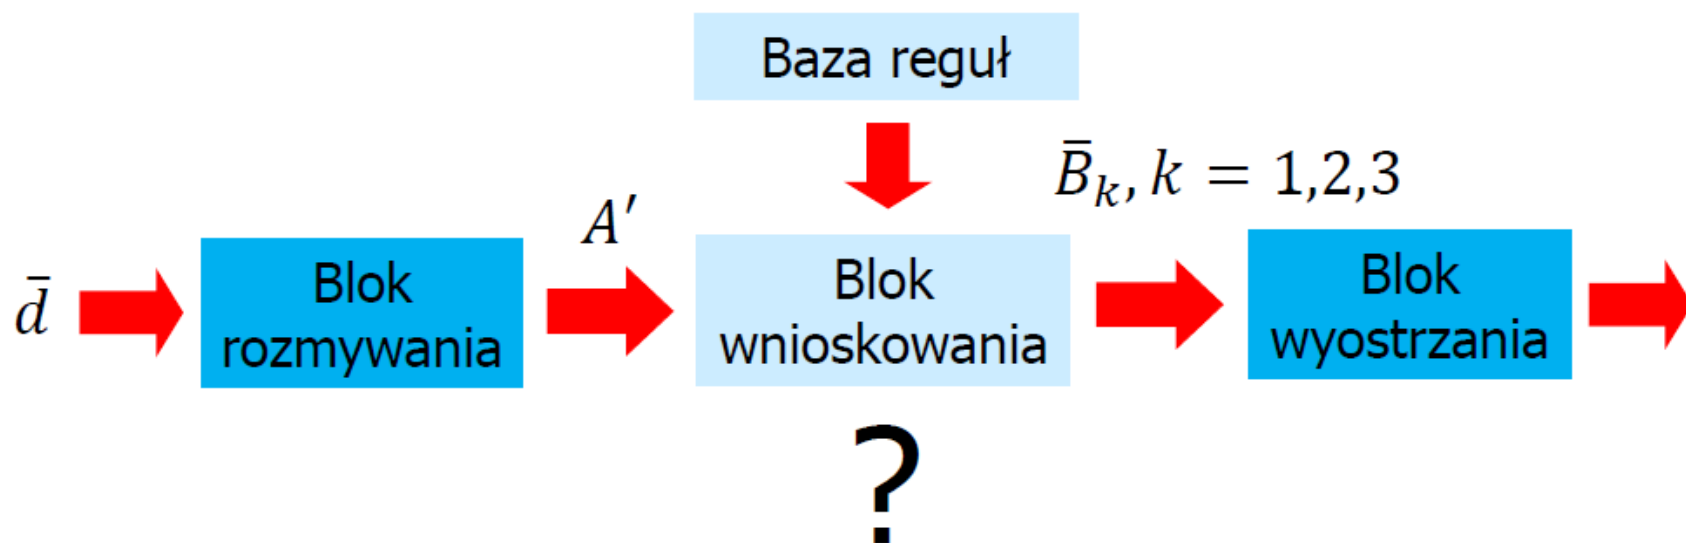


$\bar{d} = 75m$

duża

# Rozmyty system wnioskujący

Przyjmijmy, że na **wejście sterownika** podana jest pewna wartość odległości  $\bar{d} = 75m$




# Blok wnioskowania

Zbiory  $\bar{B}_k$  sumujemy i wynikowy zbiór  $\bar{B}$  jest wejście bloku wyostrzania:

$$\bar{B} = \bigcup_{k=1}^3 \bar{B}_k = \bar{B}_1 \cup \bar{B}_2 \cup \bar{B}_3$$

W naszym przykładzie otrzymamy:




# Blok wnioskowania

Zbiory  $\bar{B}_k$  sumujemy i wynikowy zbiór  $\bar{B}$  jest wejście bloku wyostrzania:

$$\bar{B} = \bigcup_{k=1}^3 \bar{B}_k = \bar{B}_1 \cup \bar{B}_2 \cup \bar{B}_3$$

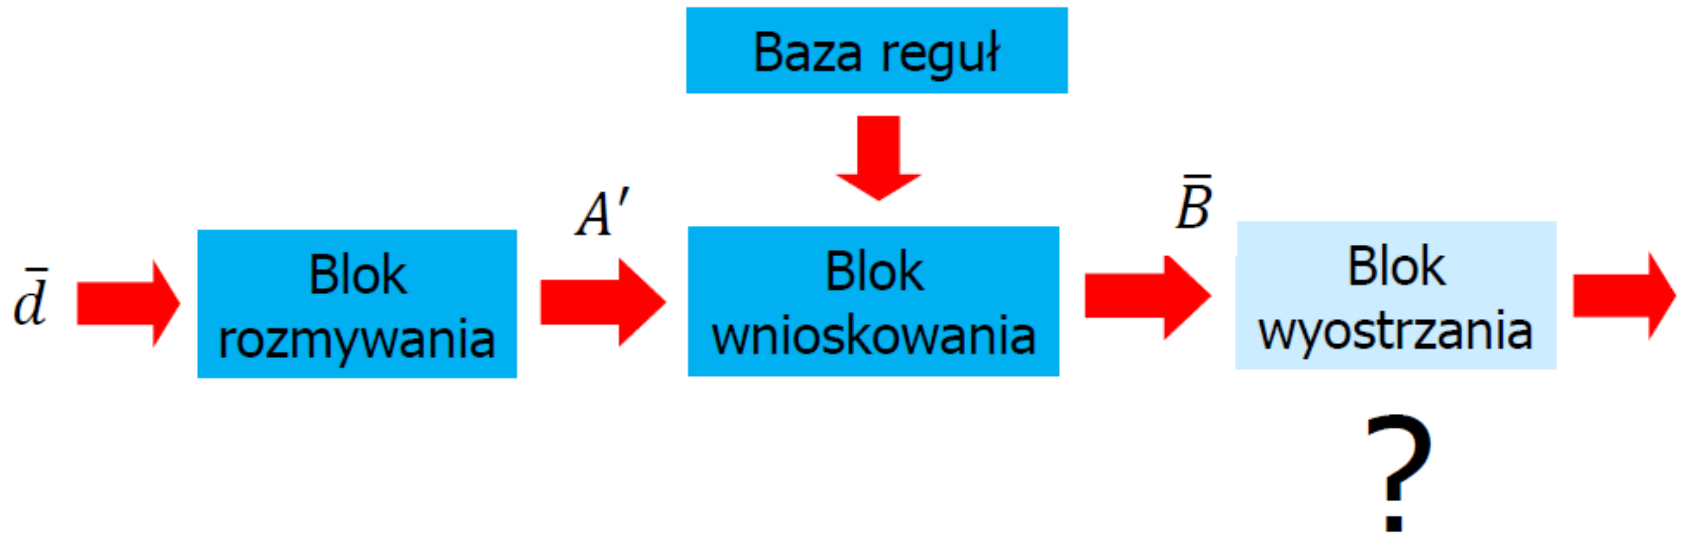
W naszym przykładzie otrzymamy:






# Rozmyty system wnioskujący

Przyjmijmy, że na **wejście sterownika** podana jest pewna wartość odległości  $\bar{d} = 75m$




# Metody wyostrzania



## **Metoda Środka Maksimum (SM) (Middle of Max (MOM))**

Ostry reprezentant  $x^*$  wynikowego zbioru rozmytego konkluzji  $B'$  zdefiniowanego funkcją przynależności  $\mu$  przyjmuje współrzędną  $x$  będącą wartością średnią wyjść dla których funkcja przynależności  $\mu$  osiąga maksimum.


# Metody wyostrzania



## Metoda Pierwszego Maksimum (PM) (Smallest of Max (SOM))

Ostry reprezentant  $x^*$  wynikowego zbioru rozmytego konkluzji B' zdefiniowanego funkcją przynależności  $\mu$  przyjmuje współrzędną  $x$  będącą najmniejszą wartością  $x$  dla której funkcja przynależności  $\mu$  osiąga maksimum.


# Metody wyostrzania



## **Metoda Maksymalnej Przynależności (MP) (Max Membership (MM))**

Ostry reprezentant  $x^*$  wynikowego zbioru rozmytego konkluzji  $B'$  zdefiniowanego funkcją przynależności  $\mu$  przyjmuje współrzędną  $x$  będącą wartością  $x$  dla której funkcja przynależności  $\mu$  osiąga maksimum.

# Metody wyostrzania




## Metoda Średniej Ważonej (ŚW) (Weighted Average (WA))

Ostry reprezentant  $x^*$  wynikowego zbioru rozmytego  $B'$  wyliczany jest ze wzoru:

$$x^* = \frac{\sum_{k=1}^N \mu_{\bar{B}_k}(\bar{x}^k) \bar{x}^k}{\sum_{k=1}^N \mu_{\bar{B}_k}(\bar{x}^k)}$$

gdzie  $\bar{x}^k$  to punkt w którym funkcja przynależności  $\mu_{\bar{B}_k}$  osiąga maksimum.

# Metody wyostrzania




**Metoda Środka Ciężkości (SC)** (Center of Gravity (COG), Center of Area (COA))

Ostry reprezentant  $x^*$  wynikowego zbioru rozmytego  $B'$  wyliczany jest ze wzoru:

$$x^* = \frac{\int \mu(x)x dx}{\int \mu(x) dx}$$

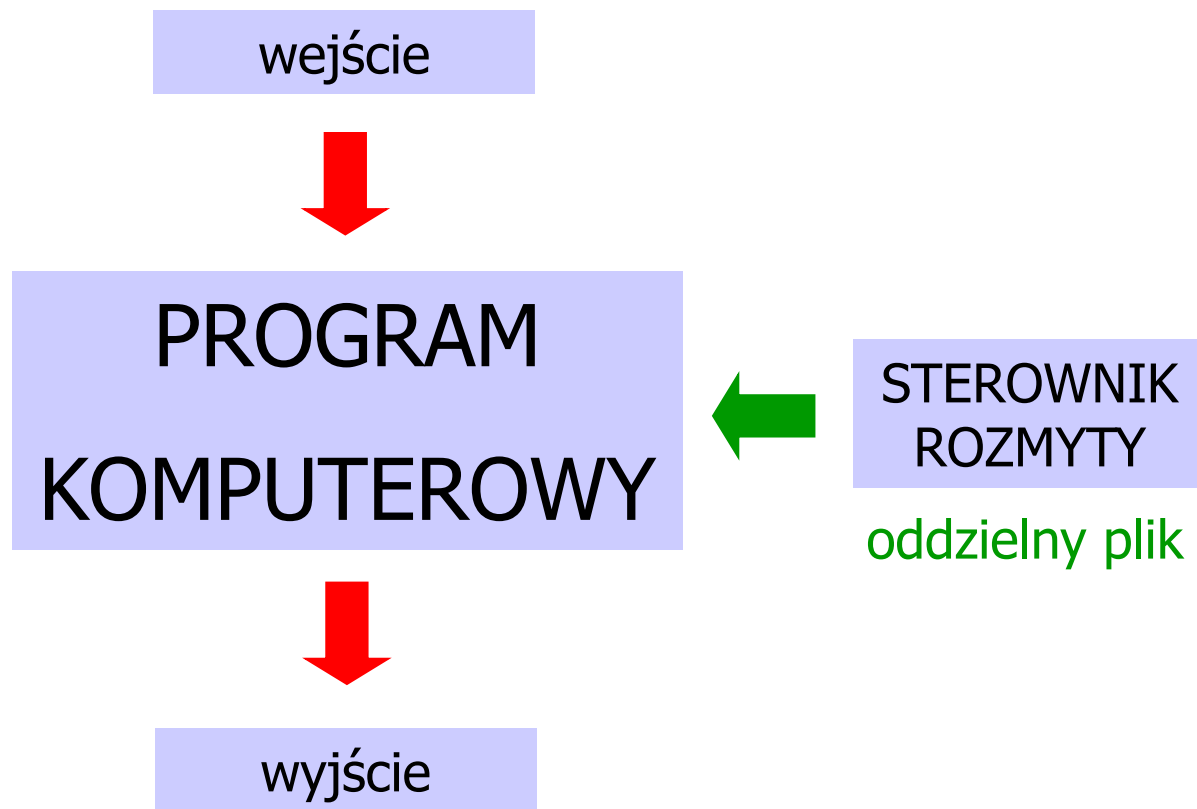
# Blok wyostrzania

W naszym przykładzie zbiór  $\bar{B}$  ma następującą funkcję przynależności:



$v^*=15$  jest wynikiem uzyskanym po zastosowaniu metody środka maksimum.

# Sterowniki rozmyte i programowanie





# Fuzzy Control Language

**Fuzzy Control Language** (FCL) to język pozwalający budować (definiować) sterowniki rozmyte.

Definicja sterownika rozmytego zapisana jest w pliku tekstowym z rozszerzeniem **fcl**.

Plik **fcl** zawiera instrukcje określające **parametry sterownika**. Instrukcje te zawarte są w następującym elemencie:

```
FUNCTION_BLOCK
```

```
//instrukcje
```

```
END_FUNCTION_BLOCK
```

# Fuzzy Control Language

Chcemy zbudować przykładowy sterownik rozmyty, który dla otrzymanej na wejściu odległości od przeszkody (odleglosc) wyznaczy nam prędkość (predkosc) pojazdu.

Wykorzystamy dwie zmienne lingwistyczne:

odleglosc (wejście sterownika)

predkosc (wyjście sterownika)

W języku FCL zapisujemy to następująco:


```
VAR_INPUT
odleglosc : REAL;
END_VAR
VAR_OUTPUT
predkosc : REAL;
END_VAR
```

# FCL - wejście

Przyjmijmy, że interesuje nas **odleglosc** w przedziale **[0,1000]** (m).

Konkretna wartość zmiennej **odleglosc** będzie podana **na wejściu** naszego sterownika. Wartość ta będzie następnie **rozmyta**.

Przyjmijmy, że zmienna **odleglosc** będzie przyjmowała następujące 3 wartości:



# FCL - wejście


## **FUZZIFY odleglosc**

```
TERM mala := (0, 1) (150, 1) (350, 0) ;
```

```
TERM srednia := (250, 0) (400,1) (600,1) (750,0) ;
```

```
TERM duza := (650, 0) (850, 1) (1000, 1) ;
```


```
END_FUZZIFY
```



# FCL - wyjście

Przyjmijmy, że interesuje nas **predkosc** w przedziale **[0,100]** (km/h). Konkretna wartość zmiennej **predkosc** będzie zwrócona **na wyjściu** naszego sterownika. Wartość ta będzie efektem wyostrzania.

Przyjmijmy, że zmienna **predkosc** będzie przyjmowała następujące 3 wartości:



# FCL - wyjście

**DEFUZZIFY predkosc**

TERM mala := (0, 1) (25, 1) (40, 0);


TERM srednia := (30, 0) (45, 1) (55, 1) (70, 0);

TERM duza := (60, 0) (75, 1) (100, 1);

METHOD : COA;

**END\_DEFUZZIFY**

**METODA WYOSTRZANIA**



# FCL - wyostrzanie

Metody wyostrzania:

**COG** - Centre of Gravity

**COGS** - Centre of Gravity for Singletons

**COA** - Centre of Area

**LM** - Left Most Maximum

**RM** - Right Most Maximum

Możemy teraz przystąpić do zdefiniowania **bazy reguł**.

# FCL – baza reguł

Przyjmijmy następującą bazę reguł:

JEŻELI **odleglosc** jest **mala** TO **predkosc** jest **mala**

JEŻELI **odleglosc** jest **srednia** TO **predkosc** jest **srednia**

JEŻELI **odleglosc** jest **duza** TO **predkosc** jest **duza**

W języku FCL zapisujemy to następująco:

```
RULE 1 : IF odleglosc IS mala THEN predkosc IS mala;  
RULE 2 : IF odleglosc IS srednia THEN predkosc IS srednia;  
RULE 3 : IF odleglosc IS duza THEN predkosc IS duza;
```



# FCL – AND i OR

Ponadto musimy określić jeszcze:

- Metodę **AND** i **OR** (do wykorzystania po lewej stronie implikacji)

Mamy do wyboru:

operator OR		operator AND	
keyword for Algorithm	Algorithm	keyword for Algorithm	Algorithm
MAX	$\text{Max } (\mu_1(x), \mu_2(x))$	MIN	$\text{Min}(\mu_1(x), \mu_2(x))$
ASUM	$\mu_1(x) + \mu_2(x) - \mu_1(x) \mu_2(x)$	PROD	$\mu_1(x) \mu_2(x)$
BSUM	$\text{Min}(1, \mu_1(x) + \mu_2(x))$	BDIF	$\text{Max}(0, \mu_1(x) + \mu_2(x) - 1)$

W języku FCL zapisujemy to następująco:

**AND** : MIN;

Wystarczy, że określimy jeden operator!

# FCL - aktywacja

Ponadto musimy określić jeszcze:

- Metodę **aktywacji** (implikacja!)

Mamy do wyboru:

Name	Keyword	Algorithm
<b>Product</b>	<b>PROD</b>	$\mu_1(x) \mu_2(x)$
<b>Minimum</b>	<b>MIN</b>	$\text{Min}(\mu_1(x), \mu_2(x))$

W języku FCL zapisujemy to następująco:

```
ACT : MIN;
```

# FCL - akumulacja

Ponadto musimy określić jeszcze:

- Metodę **akumulacji** (suma zbiorów!)

Mamy do wyboru:

Name	Keyword	Formula
Maximum	MAX	$\text{Max}(\mu_1(x), \mu_2(x))$
Bounded Sum	BSUM	$\text{Min}(1, \mu_1(x) + \mu_2(x))$
Normalised Sum	NSUM	$\frac{\mu_1(x) + \mu_2(x)}{\text{Max}(1, \text{MAX}(\mu_1(x') + \mu_2(x')) )}$

W języku FCL zapisujemy to następująco:

**ACCU** : MAX;

# FCL – blok reguł

Ostatecznie **blok reguł** w FCL wygląda następująco:

```
RULEBLOCK No1
```

```
AND : MIN;
```

```
ACT : MIN;
```

```
ACCU : MAX;
```

```
RULE 1: IF odleglosc IS mala THEN predkosc IS mala;
```

```
RULE 2: IF odleglosc IS srednia THEN predkosc IS srednia;
```

```
RULE 3 : IF odleglosc IS duza THEN predkosc IS duza;
```

```
END_RULEBLOCK
```

Jak zobaczymy bloków takich może być kilka!