

Złożoność obliczeniowa algorytmów

Aproxymowalność

Kordian A. Smoliński

Wydział Fizyki i Informatyki Stosowanej

2024/2025

Aproxymowalność

Treść wykładu

- 1 Algorytmy aproksymacyjne
 - Problemy optymalizacyjne
 - Algorytmy ϵ -aproksymacyjne
 - Minimalne pokrycie wierzchołkowe
 - Problem komiwojażera
 - Metryczny problem komiwojażera
- 2 Aproxymowalność i złożoność
 - **MaxSNP**
 - **MaxSNP**-zupełność
 - Nieaproksymowalność

Aproxymowalność

Wiele problemów o dużym znaczeniu praktycznym jest **NP**-zupełnych. Jeżeli $P \neq NP$, to żaden z nich nie ma efektywnego rozwiązania.

Aproxymowalność

Wiele problemów o dużym znaczeniu praktycznym jest **NP**-zupełnych. Jeżeli $P \neq NP$, to żaden z nich nie ma efektywnego rozwiązania.

Możliwe sposoby częściowego poradzenia sobie z problemami **NP**-zupełnymi:

Aproxymowalność

Wiele problemów o dużym znaczeniu praktycznym jest **NP**-zupełnych. Jeżeli $P \neq NP$, to żaden z nich nie ma efektywnego rozwiązania.

Możliwe sposoby częściowego poradzenia sobie z problemami **NP**-zupełnymi:

- poszukiwanie podproblemów, mających rozwiązania o wielomianowej złożoności czasowej;

Aproxymowalność

Wiele problemów o dużym znaczeniu praktycznym jest **NP**-zupełnych. Jeżeli $P \neq NP$, to żaden z nich nie ma efektywnego rozwiązania.

Możliwe sposoby częściowego poradzenia sobie z problemami **NP**-zupełnymi:

- poszukiwanie podproblemów, mających rozwiązania o wielomianowej złożoności czasowej;
- konstruowanie **algorytmów aproksymacyjnych**, nierozwiązujących dokładnie problemu, ale wyznaczających rozwiązania przybliżone.

Algorytmy aproksymacyjne

Rozwiązań problemów decyzyjnych nie można przybliżać — wymagają odpowiedzi „tak” albo „nie”.

Algorytmy aproksymacyjne

Rozwiązań problemów decyzyjnych nie można przybliżyć — wymagają odpowiedzi „tak” albo „nie”.

Możemy przybliżać rozwiązania problemów, dla których rozwiązaniem konkretnego przypadku jest pewien element ze zbioru rozwiązań dopuszczalnych.

Algorytmy aproksymacyjne

Rozwiązań problemów decyzyjnych nie można przybliżyć — wymagają odpowiedzi „tak” albo „nie”.

Możemy przybliżać rozwiązania problemów, dla których rozwiązaniem konkretnego przypadku jest pewien element ze zbioru rozwiązań dopuszczalnych.

Określając na elementach zbioru rozwiązań dopuszczalnych funkcję celu, możemy żądać, aby znaleziona odpowiedź minimalizowała bądź maksymalizowała wartość tej funkcji po wszystkich rozwiązaniach dopuszczalnych.

Algorytmy aproksymacyjne

Rozwiązań problemów decyzyjnych nie można przybliżyć — wymagają odpowiedzi „tak” albo „nie”.

Możemy przybliżać rozwiązania problemów, dla których rozwiązaniem konkretnego przypadku jest pewien element ze zbioru rozwiązań dopuszczalnych.

Określając na elementach zbioru rozwiązań dopuszczalnych funkcję celu, możemy żądać, aby znaleziona odpowiedź minimalizowała bądź maksymalizowała wartość tej funkcji po wszystkich rozwiązaniach dopuszczalnych.

Problemy o powyższej charakterystyce nazywamy **problemami optymalizacyjnymi**.

Problemy optymalizacyjne

Definicja

W problemie optymalizacyjnym Π określamy:

Problemy optymalizacyjne

Definicja

W problemie optymalizacyjnym Π określamy:
zbiór przypadków D ; $\forall x \in D$ określamy

Problemy optymalizacyjne

Definicja

W problemie optymalizacyjnym Π określamy:

zbiór przypadków D ; $\forall x \in D$ określamy

zbiór rozwiązań dopuszczalnych $F(x)$; $\forall s \in F(x)$ określamy

Problemy optymalizacyjne

Definicja

W problemie optymalizacyjnym Π określamy:

zbiór przypadków D ; $\forall x \in D$ określamy

zbiór rozwiązań dopuszczalnych $F(x)$; $\forall s \in F(x)$ określamy

koszt $c(s) \in \mathbb{N}$.

Problemy optymalizacyjne

Definicja

W problemie optymalizacyjnym Π określamy:
zbiór przypadków D ; $\forall x \in D$ określamy
zbiór rozwiązań dopuszczalnych $F(x)$; $\forall s \in F(x)$ określamy
koszt $c(s) \in \mathbb{N}$.

Definicja

Rozwiązaniem **optymalnym** minimalizacji (maksymalizacji)
dla przypadku $x \in D$ problemu Π jest $s \in F(x)$ takie, że

$$c(s) = \text{opt}(x) = \min_{s' \in F(x)} c(s') \quad \left(\max_{s' \in F(x)} c(s') \right).$$

Wartość $\text{opt}(x)$ nazywamy **optimum**.

Problemy optymalizacyjne

Niech $|x|$ będzie rozmiarem przypadku $x \in D$ problemu optymalizacyjnego Π . Jeżeli:

Problemy optymalizacyjne

Niech $|x|$ będzie rozmiarem przypadku $x \in D$ problemu optymalizacyjnego Π . Jeżeli:

- $\forall_{s \in F(x)} |s|$ jest ograniczone wielomianowo w $|x|$;

Problemy optymalizacyjne

Niech $|x|$ będzie rozmiarem przypadku $x \in D$ problemu optymalizacyjnego Π . Jeżeli:

- $\forall_{s \in F(x)} |s|$ jest ograniczone wielomianowo w $|x|$;
- języki $\{x: x \in D\}$ i $\{y: y \in F(x)\}$ są rozstrzygalne w czasie wielomianowym;

Problemy optymalizacyjne

Niech $|x|$ będzie rozmiarem przypadku $x \in D$ problemu optymalizacyjnego Π . Jeżeli:

- $\forall s \in F(x)$ $|s|$ jest ograniczone wielomianowo w $|x|$;
- języki $\{x: x \in D\}$ i $\{y: y \in F(x)\}$ są rozstrzygalne w czasie wielomianowym;
- $\forall x \in D \forall y \in F(x)$ $c(y)$ można obliczyć w czasie wielomianowym;

Problemy optymalizacyjne

Niech $|x|$ będzie rozmiarem przypadku $x \in D$ problemu optymalizacyjnego Π . Jeżeli:

- $\forall_{s \in F(x)} |s|$ jest ograniczone wielomianowo w $|x|$;
- języki $\{x: x \in D\}$ i $\{y: y \in F(x)\}$ są rozstrzygalne w czasie wielomianowym;
- $\forall_{x \in D} \forall_{y \in F(x)} c(y)$ można obliczyć w czasie wielomianowym;

to Π jest problemem **NP**-optymalizacyjnym.

Problemy optymalizacyjne

Z Π wiążemy **problem decyzyjny**:

Problem (Σ)

Czy dla przypadku $x \in D$ problemu Π i liczby $B \in \mathbb{R}_+$ istnieje rozwiązanie dopuszczalne $s \in F(x)$ dla którego $c(s) < B$ ($c(s) > B$)?

Problemy optymalizacyjne

Z Π wiążemy **problem decyzyjny**:

Problem (Σ)

Czy dla przypadku $x \in D$ problemu Π i liczby $B \in \mathbb{R}_+$ istnieje rozwiązanie dopuszczalne $s \in F(x)$ dla którego $c(s) < B$ ($c(s) > B$)?

- Znając $\text{opt}(x)$ można natychmiast podać odpowiedź dla problemu Σ .

Problemy optymalizacyjne

Z Π wiążemy **problem decyzyjny**:

Problem (Σ)

Czy dla przypadku $x \in D$ problemu Π i liczby $B \in \mathbb{R}_+$ istnieje rozwiązanie dopuszczalne $s \in F(x)$ dla którego $c(s) < B$ ($c(s) > B$)?

- Znając $\text{opt}(x)$ można natychmiast podać odpowiedź dla problemu Σ .
- Używając algorytmu rozwiązującego Σ można wyznaczyć $\text{opt}(x)$ za pomocą wyszukiwania binarnego.

Problemy optymalizacyjne

Z Π wiążemy **problem decyzyjny**:

Problem (Σ)

Czy dla przypadku $x \in D$ problemu Π i liczby $B \in \mathbb{R}_+$ istnieje rozwiązanie dopuszczalne $s \in F(x)$ dla którego $c(s) < B$ ($c(s) > B$)?

- Znając $\text{opt}(x)$ można natychmiast podać odpowiedź dla problemu Σ .
- Używając algorytmu rozwiązującego Σ można wyznaczyć $\text{opt}(x)$ za pomocą wyszukiwania binarnego.

Problem **NP**-trudny

Jeżeli problem decyzyjny Σ jest **NP**-zupełny, to skojarzony z nim problem optymalizacyjny Π jest **NP-trudny**.

Definicja

Niech \mathcal{A} będzie algorytmem działającym w czasie wielomianowym, którego słowami wejściowymi są przypadki problemu Π . Jeżeli $\forall_{x \in D} \mathcal{A}(x) \in F(x)$, to nazywamy go **algorytmem aproxymacyjnym** dla problemu **NP**-optymalizacyjnego Π .

Definicja

Niech \mathcal{A} będzie algorytmem działającym w czasie wielomianowym, którego słowami wejściowymi są przypadki problemu Π . Jeżeli $\forall_{x \in D} \mathcal{A}(x) \in F(x)$, to nazywamy go **algorytmem aproxymacyjnym** dla problemu **NP**-optymalizacyjnego Π .

- \mathcal{A} znajduje rozwiązanie dopuszczalne dla $x \in D$.

Definicja

Niech \mathcal{A} będzie algorytmem działającym w czasie wielomianowym, którego słowami wejściowymi są przypadki problemu Π . Jeżeli $\forall_{x \in D} \mathcal{A}(x) \in F(x)$, to nazywamy go **algorytmem aproxymacyjnym** dla problemu **NP**-optymalizacyjnego Π .

- \mathcal{A} znajduje rozwiązanie dopuszczalne dla $x \in D$.
- Interesują nas rozwiązania dopuszczalne będące **przybliżeniami** rozwiązania optymalnego.

Algorytmy ϵ -aproxymacyjne

Definicja

Algorytm \mathcal{A} jest ϵ -aproxymacyjny, jeżeli $\forall_{x \in D} \mathcal{A}(x) \in F(x)$ oraz

$$\exists \epsilon \geq 0: \frac{|c(\mathcal{A}(x)) - \text{opt}(x)|}{\max\{c(\mathcal{A}(x)), \text{opt}(x)\}} \leq \epsilon.$$

Algorytmy ϵ -aproxymacyjne

Definicja

Algorytm \mathcal{A} jest ϵ -aproxymacyjny, jeżeli $\forall x \in D \mathcal{A}(x) \in F(x)$ oraz

$$\exists \epsilon \geq 0: \frac{|c(\mathcal{A}(x)) - \text{opt}(x)|}{\max\{c(\mathcal{A}(x)), \text{opt}(x)\}} \leq \epsilon.$$

- dla minimalizacji $c(\mathcal{A}(x)) \leq \frac{\text{opt}(x)}{1 - \epsilon}$;

Algorytmy ϵ -aproxymacyjne

Definicja

Algorytm \mathcal{A} jest ϵ -aproxymacyjny, jeżeli $\forall x \in D \mathcal{A}(x) \in F(x)$ oraz

$$\exists \epsilon \geq 0: \frac{|c(\mathcal{A}(x)) - \text{opt}(x)|}{\max\{c(\mathcal{A}(x)), \text{opt}(x)\}} \leq \epsilon.$$

- dla minimalizacji $c(\mathcal{A}(x)) \leq \frac{\text{opt}(x)}{1 - \epsilon}$;
- dla maksymalizacji $c(\mathcal{A}(x)) \geq (1 - \epsilon) \text{opt}(x)$;

Algorytmy ϵ -aproxymacyjne

Definicja

Algorytm \mathcal{A} jest ϵ -aproxymacyjny, jeżeli $\forall x \in D \mathcal{A}(x) \in F(x)$ oraz

$$\exists \epsilon \geq 0: \frac{|c(\mathcal{A}(x)) - \text{opt}(x)|}{\max\{c(\mathcal{A}(x)), \text{opt}(x)\}} \leq \epsilon.$$

- dla minimalizacji $c(\mathcal{A}(x)) \leq \frac{\text{opt}(x)}{1 - \epsilon}$;
- dla maksymalizacji $c(\mathcal{A}(x)) \geq (1 - \epsilon) \text{opt}(x)$;
- jeżeli $\epsilon = 0$, to $\mathcal{A}(x)$ jest rozwiązaniem optymalnym;

Algorytmy ϵ -aproxymacyjne

Definicja

Algorytm \mathcal{A} jest ϵ -aproxymacyjny, jeżeli $\forall x \in D \mathcal{A}(x) \in F(x)$ oraz

$$\exists \epsilon \geq 0: \frac{|c(\mathcal{A}(x)) - \text{opt}(x)|}{\max\{c(\mathcal{A}(x)), \text{opt}(x)\}} \leq \epsilon.$$

- dla minimalizacji $c(\mathcal{A}(x)) \leq \frac{\text{opt}(x)}{1 - \epsilon}$;
- dla maksymalizacji $c(\mathcal{A}(x)) \geq (1 - \epsilon) \text{opt}(x)$;
- jeżeli $\epsilon = 0$, to $\mathcal{A}(x)$ jest rozwiązaniem optymalnym;
- jeżeli $\epsilon = 1$, to \mathcal{A} jest **heurystyką**, a $\mathcal{A}(x)$ może być dowolnie odległe od rozwiązania optymalnego.

Algorytmy ϵ -aproxymacyjne

Definicja

Algorytm \mathcal{A} jest ϵ -aproxymacyjny, jeżeli $\forall x \in D \mathcal{A}(x) \in F(x)$ oraz

$$\exists \epsilon \geq 0: \frac{|c(\mathcal{A}(x)) - \text{opt}(x)|}{\max\{c(\mathcal{A}(x)), \text{opt}(x)\}} \leq \epsilon.$$

- dla minimalizacji $c(\mathcal{A}(x)) \leq \frac{\text{opt}(x)}{1 - \epsilon}$;
- dla maksymalizacji $c(\mathcal{A}(x)) \geq (1 - \epsilon) \text{opt}(x)$;
- jeżeli $\epsilon = 0$, to $\mathcal{A}(x)$ jest rozwiązaniem optymalnym;
- jeżeli $\epsilon = 1$, to \mathcal{A} jest **heurystyką**, a $\mathcal{A}(x)$ może być dowolnie odległe od rozwiązania optymalnego.

Definicja

$\inf\{\epsilon > 0: \exists \text{ algorytm } \epsilon\text{-aproxymacyjny dla } \Pi\}$ to **próg aproxymacji** problemu Π .

Problem (MINIMUM NODE COVER)

Problem (MINIMUM NODE COVER)

Wejście: $G(V, E)$

Minimalne pokrycie wierzchołkowe

Problem (MINIMUM NODE COVER)

Wejście: $G(V, E)$

Wyjście: $C \subseteq V$ takie, że $\text{opt}(G) = |C| = \min_{V' \subseteq V} \{|V'| : V' \text{ jest pokryciem wierzchołkowym } G\}$

Minimalne pokrycie wierzchołkowe

Problem (MINIMUM NODE COVER)

Wejście: $G(V, E)$

Wyjście: $C \subseteq V$ takie, że $\text{opt}(G) = |C| = \min_{V' \subseteq V} \{|V'| : V' \text{ jest pokryciem wierzchołkowym } G\}$

- dopuszczalność rozwiązania można sprawdzić w czasie liniowym od rozmiaru grafu;

Minimalne pokrycie wierzchołkowe

Problem (MINIMUM NODE COVER)

Wejście: $G(V, E)$

Wyjście: $C \subseteq V$ takie, że $\text{opt}(G) = |C| = \min_{V' \subseteq V} \{|V'| : V' \text{ jest pokryciem wierzchołkowym } G\}$

- dopuszczalność rozwiązania można sprawdzić w czasie liniowym od rozmiaru grafu;
- funkcję celu można obliczyć w czasie liniowym od rozmiaru grafu.

Minimalne pokrycie wierzchołkowe

Problem (MINIMUM NODE COVER)

Wejście: $G(V, E)$

Wyjście: $C \subseteq V$ takie, że $\text{opt}(G) = |C| = \min_{V' \subseteq V} \{|V'| : V' \text{ jest pokryciem wierzchołkowym } G\}$

- dopuszczalność rozwiązania można sprawdzić w czasie liniowym od rozmiaru grafu;
- funkcję celu można obliczyć w czasie liniowym od rozmiaru grafu.

Pełne przeszukanie

Algorytm przeprowadzający pełne przeszukanie działa w czasie $2^{|C|} |V|^{O(1)}$.

Minimalne pokrycie wierzchołkowe

Zadanie równoważne do MINIMUM NODE COVER:

Minimalne pokrycie wierzchołkowe

Zadanie równoważne do MINIMUM NODE COVER:

Przykład (programowanie liniowe binarne)

Dla grafu $G = (V, E)$ znajdź

$$c = \min \sum_{v \in V} x_v$$

przy warunku

$$\forall_{\{v,w\} \in E} x_v + x_w \geq 1$$

gdzie $\forall_{v \in V} x_v \in \{0, 1\}$.

Minimalne pokrycie wierzchołkowe

Algorytm zachłanny

```
 $\tilde{C} \leftarrow \emptyset$   
while  $|E| > 0$  do  
    wybierz wierzchołek  $v \in V$  o największym stopniu  
     $\tilde{C} \leftarrow \tilde{C} \cup \{v\}$   
     $G \leftarrow G \setminus \{v\}$   
end while
```

Heurystyka

Powyższy algorytm nie jest algorytmem ϵ -aproxymacyjnym dla **żadnego** $\epsilon < 1$ — współczynnik błędu rośnie jak $\log |V|$.

Minimalne pokrycie wierzchołkowe

Algorytm skojarzeniowy

$\tilde{C} \leftarrow \emptyset$

while $|E| > 0$ **do**

 wybierz dowolną krawędź $\{v, w\} \in E$

$\tilde{C} \leftarrow \tilde{C} \cup \{v, w\}$

$G \leftarrow G \setminus \{v, w\}$

end while

Lemat

Podany algorytm tworzy skojarzenie maksymalne.

Dowód.

Każda para dodana do \tilde{C} jest **jedyna**: algorytm nie doda krawędzi $\{v, w\}$ i $\{v, u\}$, bo gdy trafi na $\{v, w\}$ doda v i w , więc krawędź $\{v, u\}$ jest pokryta przez wierzchołek v . Zatem algorytm tworzy w G **skojarzenie** i jest ono **maksymalne**, bo iterowanie trwa dopóki są niepokryte krawędzie. □

Minimalne pokrycie wierzchołkowe

Lemat

Dla dowolnego skojarzenia maksymalnego M w grafie G

$$\text{opt}(G) \geq |M|.$$

Minimalne pokrycie wierzchołkowe

Lemat

Dla dowolnego skojarzenia maksymalnego M w grafie G

$$\text{opt}(G) \geq |M|.$$

Dowód.

Do skojarzenia maksymalnego nie można dodać więcej krawędzi (z definicji), więc każda pozostała krawędź sąsiaduje z przynajmniej jedną krawędzią z M . Jeżeli weźmiemy oba końce wszystkich krawędzi w M jako pokrycie wierzchołkowe V' , to wszystkie krawędzie wewnątrz V' są pokryte, a wszystkie pozostałe krawędzie dochodzą do V' (bo sąsiadują z M). Zatem $|V'| \geq |M|$, bo V' musi łączyć przynajmniej jeden z końców wszystkich krawędzi w M , aby pokryć wszystkie krawędzie w G . □

Minimalne pokrycie wierzchołkowe

Fakt

Próg aproksymacji problemu MINIMUM NODE COVER nie mniejszy niż $\frac{1}{2}$.

Minimalne pokrycie wierzchołkowe

Fakt

Próg aproksymacji problemu MINIMUM NODE COVER nie mniejszy niż $\frac{1}{2}$.

Dowód.

Z algorytmu i 1. Lematu wnioskujemy, że $|\mathcal{A}(G)| = 2|M|$ (bierzemy **oba** wierzchołki skojarzenia). Zestawiając to z wynikiem 2. Lematu, mamy

$$\text{opt}(G) \geq |M| = \frac{1}{2}|\mathcal{A}(G)|,$$

czyli

$$\frac{|c(\mathcal{A}(G)) - \text{opt}(G)|}{|c(\mathcal{A}(G))|} \leq \frac{1}{2},$$

tzn. rozmiar pokrycia wierzchołkowego otrzymanego z algorytmu jest mniej niż dwukrotnie większy od rozmiaru minimalnego pokrycia wierzchołkowego.



Problem komiwojażera

TSP (*Travelling Salesman Problem*)

Problem (TSP)

Problem komiwojażera

TSP (*Travelling Salesman Problem*)

Problem (TSP)

Wejście: $G(V, E)$, $w: E \rightarrow \mathbb{N}$

Problem komiwojażera

TSP (*Travelling Salesman Problem*)

Problem (TSP)

Wejście: $G(V, E)$, $w: E \rightarrow \mathbb{N}$

Wyjście: cykl Hamiltona C w G taki, że

$c(C) = \min_{C' \in G} \{c(C') : C' \text{ cykl Hamiltona w } G\}$, gdzie

$c(C') = \sum_{e \in E(C')} w(e)$

Problem komiwojażera

TSP (*Travelling Salesman Problem*)

Problem (TSP)

Wejście: $G(V, E)$, $w: E \rightarrow \mathbb{N}$

Wyjście: cykl Hamiltona C w G taki, że

$$c(C) = \min_{C' \in G} \{c(C') : C' \text{ cykl Hamiltona w } G\}, \text{ gdzie} \\ c(C') = \sum_{e \in E(C')} w(e)$$

Twierdzenie

Jeżeli $P \neq NP$, to próg aproksymacyjny dla TSP wynosi 1.

Problem komiwojażera

Dowód.

Przypuśćmy, że dla pewnego $\epsilon < 1$ istnieje wielomianowy algorytm ϵ -aproxymacyjny \mathcal{A} dla TSP. \mathcal{A} mógłby zostać użyty do rozwiązania HAMILTONIAN CYCLE w czasie wielomianowym.

Problem komiwojażera

Dowód.

Przypuśćmy, że dla pewnego $\epsilon < 1$ istnieje wielomianowy algorytm ϵ -aproxymacyjny \mathcal{A} dla TSP. \mathcal{A} mógłby zostać użyty do rozwiązania HAMILTONIAN CYCLE w czasie wielomianowym.

Redukujemy HAMILTONIAN CYCLE dla grafu $G = (V, E)$ do TSP na grafie pełnym $G' = (V, V \times V)$ z

$$w(\{u, v\}) = \begin{cases} 1 & \{u, v\} \in E \\ \frac{|V|}{1-\epsilon} & \{u, v\} \notin E. \end{cases}$$

Problem komiwojażera

Dowód.

Przypuśćmy, że dla pewnego $\epsilon < 1$ istnieje wielomianowy algorytm ϵ -aproxymacyjny \mathcal{A} dla TSP. \mathcal{A} mógłby zostać użyty do rozwiązania HAMILTONIAN CYCLE w czasie wielomianowym.

Redukujemy HAMILTONIAN CYCLE dla grafu $G = (V, E)$ do TSP na grafie pełnym $G' = (V, V \times V)$ z

$$w(\{u, v\}) = \begin{cases} 1 & \{u, v\} \in E \\ \frac{|V|}{1-\epsilon} & \{u, v\} \notin E. \end{cases}$$

Uruchamiamy \mathcal{A} na G' . Jeżeli G ma cykl Hamiltona, to $c(\mathcal{A}(G')) = |V|$. Jeżeli G nie ma cyklu Hamiltona, to każdy cykl Hamiltona w G' zawiera przynajmniej jedną krawędź o wadze $\frac{|V|}{1-\epsilon}$, więc $c(\mathcal{A}(G')) > \frac{|V|}{1-\epsilon}$. W drugą stronę — ponieważ \mathcal{A} jest ϵ -aproxymacyjny, więc wnioskujemy, że $\text{opt}(G) > V$ i G nie może mieć cyklu Hamiltona.

Problem komiwojażera

Dowód.

Przypuśćmy, że dla pewnego $\epsilon < 1$ istnieje wielomianowy algorytm ϵ -aproxymacyjny \mathcal{A} dla TSP. \mathcal{A} mógłby zostać użyty do rozwiązania HAMILTONIAN CYCLE w czasie wielomianowym.

Redukujemy HAMILTONIAN CYCLE dla grafu $G = (V, E)$ do TSP na grafie pełnym $G' = (V, V \times V)$ z

$$w(\{u, v\}) = \begin{cases} 1 & \{u, v\} \in E \\ \frac{|V|}{1-\epsilon} & \{u, v\} \notin E. \end{cases}$$

Uruchamiamy \mathcal{A} na G' . Jeżeli G ma cykl Hamiltona, to $c(\mathcal{A}(G')) = |V|$. Jeżeli G nie ma cyklu Hamiltona, to każdy cykl Hamiltona w G' zawiera przynajmniej jedną krawędź o wadze $\frac{|V|}{1-\epsilon}$, więc $c(\mathcal{A}(G')) > \frac{|V|}{1-\epsilon}$. W drugą stronę — ponieważ \mathcal{A} jest ϵ -aproxymacyjny, więc wnioskujemy, że $\text{opt}(G) > V$ i G nie może mieć cyklu Hamiltona.

G ma cykl Hamiltona wtedy i tylko wtedy, gdy $c(\mathcal{A}(G')) = |V|$, co można sprawdzić w czasie wielomianowym. Ponieważ HAMILTONIAN CYCLE jest **NP**-zupełny, więc **P** = **NP**, co przeczyłoby założeniu, lub algorytm \mathcal{A} nie istnieje. □

Metryczny problem komiwojażera

Δ -TSP

Problem (Δ -TSP)

Metryczny problem komiwojażera

Δ -TSP

Problem (Δ -TSP)

Wejście: $G(V, E)$, $w: V \times V \rightarrow \mathbb{N}$ spełniająca nierówność trójkąta: $\forall u, v, z \in V: w(u, v) \leq w(u, z) + w(v, z)$

Metryczny problem komiwojażera

Δ -TSP

Problem (Δ -TSP)

Wejście: $G(V, E)$, $w: V \times V \rightarrow \mathbb{N}$ spełniająca nierówność trójkąta: $\forall u, v, z \in V: w(u, v) \leq w(u, z) + w(v, z)$

Wyjście: cykl Hamiltona C w G taki, że
 $w(C) = \min_{C' \in G} \{w(C'): C' \text{ cykl Hamiltona w } G\}$, gdzie
 $w(C') = \sum_{e \in E(C')} w(e)$ ($w(\{u, v\}) \equiv w(u, v)$)

Metryczny problem komiwojażera

Δ -TSP

Problem (Δ -TSP)

Wejście: $G(V, E)$, $w: V \times V \rightarrow \mathbb{N}$ spełniająca nierówność trójkąta: $\forall u, v, z \in V: w(u, v) \leq w(u, z) + w(v, z)$

Wyjście: cykl Hamiltona C w G taki, że
 $w(C) = \min_{C' \in G} \{w(C'): C' \text{ cykl Hamiltona w } G\}$, gdzie
 $w(C') = \sum_{e \in E(C')} w(e)$ ($w(\{u, v\}) \equiv w(u, v)$)

Fakt

Istnieje algorytm $\frac{1}{2}$ -aproxymacyjny dla Δ -TSP.

„Hierarchia” rozwiązań problemów optymalizacyjnych

1 dokładny algorytm wielomianowy

Aproxymowalność i złożoność

„Hierarchia” rozwiązań problemów optymalizacyjnych

- 1 **dokładny** algorytm wielomianowy
- 2 wielomianowy algorytm aproksymacyjny

Aproxymowalność i złożoność

„Hierarchia” rozwiązań problemów optymalizacyjnych

- 1 **dokładny** algorytm wielomianowy
- 2 wielomianowy algorytm aproksymacyjny

Problem

*Dla jakich problemów **NP**-optymalizacyjnych istnieją wielomianowe algorytmy aproksymacyjne?*

Definicje

Formuły logiki rzędu

Definicje

Formuły logiki rzędu

- 0 zawierają **zmienne zdaniowe** i **spójniki zdaniowe** —
rachunek zdań — np. $x \in P \vee x \notin P$;

Definicje

Formuły logiki rzędu

- 0 zawierają **zmienne zdaniowe** i **spójniki zdaniowe** — **rachunek zdań** — np. $x \in P \vee x \notin P$;
- 1 zawierają ponadto kwantyfikatory oparte na elementach — **rachunek kwantyfikatorów** — $\forall_x (x \in P \vee x \notin P)$

Definicje

Formuły logiki rzędu

- 0 zawierają **zmienne zdaniowe** i **spójniki zdaniowe** — **rachunek zdań** — np. $x \in P \vee x \notin P$;
- 1 zawierają ponadto kwantyfikatory oparte na elementach — **rachunek kwantyfikatorów** — $\forall_x (x \in P \vee x \notin P)$
- 2 zawierają ponadto kwantyfikatory oparte na relacjach — $\forall_P \forall_x (x \in P \vee x \notin P)$

Definicje

Formuły logiki rzędu

- 0 zawierają **zmienne zdaniowe** i **spójniki zdaniowe** — **rachunek zdań** — np. $x \in P \vee x \notin P$;
- 1 zawierają ponadto kwantyfikatory oparte na elementach — **rachunek kwantyfikatorów** — $\forall_x (x \in P \vee x \notin P)$
- 2 zawierają ponadto kwantyfikatory oparte na relacjach — $\forall_P \forall_x (x \in P \vee x \notin P)$

Egzystencjalna logika 2. rzędu **SO \exists** — klasa formuł, w których wszystkie kwantyfikatory 2. rzędu są egzystencjalne (tj. \exists).

Definicje

Formuły logiki rzędu

- 0 zawierają **zmienne zdaniowe** i **spójniki zdaniowe** — **rachunek zdań** — np. $x \in P \vee x \notin P$;
- 1 zawierają ponadto kwantyfikatory oparte na elementach — **rachunek kwantyfikatorów** — $\forall_x (x \in P \vee x \notin P)$
- 2 zawierają ponadto kwantyfikatory oparte na relacjach — $\forall_P \forall_x (x \in P \vee x \notin P)$

Egzystencjalna logika 2. rzędu **SO \exists** — klasa formuł, w których wszystkie kwantyfikatory 2. rzędu są egzystencjalne (tj. \exists).

Twierdzenie (Fagin)

$$\text{NP} = \text{SO}\exists.$$

Definicja

SNP (**StrictNP**) — klasa formuł z **SO \exists** , w których wszystkie kwantyfikatory 1. rzędu są uniwersalne (tj. \forall).

Definicja

SNP (**StrictNP**) — klasa formuł z **SO \exists** , w których wszystkie kwantyfikatory 1. rzędu są uniwersalne (tj. \forall).

Przykład (formuła z **SNP**)

$$\exists s \forall x_1 \forall x_2 \dots \forall x_k \phi$$

MaxSNP

Definicja

SNP (**StrictNP**) — klasa formuł z **SO \exists** , w których wszystkie kwantyfikatory 1. rzędu są uniwersalne (tj. \forall).

Przykład (formuła z **SNP**)

$$\exists s \forall x_1 \forall x_2 \dots \forall x_k \phi$$

Definicja

MaxSNP₀ — klasa problemów optymalizacyjnych określanych przez formułę

$$\max_s |\{(x_1, x_2, \dots, x_k) : \phi\}|$$

MaxSNP

Definicja

SNP (**StrictNP**) — klasa formuł z **SO \exists** , w których wszystkie kwantyfikatory 1. rzędu są uniwersalne (tj. \forall).

Przykład (formuła z **SNP**)

$$\exists S \forall x_1 \forall x_2 \dots \forall x_k \phi$$

Definicja

MaxSNP₀ — klasa problemów optymalizacyjnych określanych przez formułę

$$\max_S |\{(x_1, x_2, \dots, x_k) : \phi\}|$$

Szukamy takiej relacji S , że formuła ϕ zachodzi dla tak wielu krotek (x_1, x_2, \dots, x_k) , jak to tylko możliwe.

Definicja

Niech Π_1 i Π_2 będą problemami optymalizacyjnymi z kosztami odpowiednio c_1 i c_2 . Para funkcji f i g tworzy **L-redukcję** jeżeli zachodzą następujące warunki:

Definicja

Niech Π_1 i Π_2 będą problemami optymalizacyjnymi z kosztami odpowiednio c_1 i c_2 . Para funkcji f i g tworzy **L-redukcję** jeżeli zachodzą następujące warunki:

- f i g są obliczalne w czasie wielomianowym;

Definicja

Niech Π_1 i Π_2 będą problemami optymalizacyjnymi z kosztami odpowiednio c_1 i c_2 . Para funkcji f i g tworzy **L-redukcję** jeżeli zachodzą następujące warunki:

- f i g są obliczalne w czasie wielomianowym;
- $x \in D_1 \implies f(x) \in D_2$;

Definicja

Niech Π_1 i Π_2 będą problemami optymalizacyjnymi z kosztami odpowiednio c_1 i c_2 . Para funkcji f i g tworzy **L-redukcję** jeżeli zachodzą następujące warunki:

- f i g są obliczalne w czasie wielomianowym;
- $x \in D_1 \implies f(x) \in D_2$;
- $s \in F_2(f(x)) \implies g(s) \in F_1(x)$;

Definicja

Niech Π_1 i Π_2 będą problemami optymalizacyjnymi z kosztami odpowiednio c_1 i c_2 . Para funkcji f i g tworzy **L-redukcję** jeżeli zachodzą następujące warunki:

- f i g są obliczalne w czasie wielomianowym;
- $x \in D_1 \implies f(x) \in D_2$;
- $s \in F_2(f(x)) \implies g(s) \in F_1(x)$;
- $\exists_{\alpha > 0} \text{opt}_2(f(x)) \leq \alpha \text{opt}_1(x)$;

Definicja

Niech Π_1 i Π_2 będą problemami optymalizacyjnymi z kosztami odpowiednio c_1 i c_2 . Para funkcji f i g tworzy **L-redukcję** jeżeli zachodzą następujące warunki:

- f i g są obliczalne w czasie wielomianowym;
- $x \in D_1 \implies f(x) \in D_2$;
- $s \in F_2(f(x)) \implies g(s) \in F_1(x)$;
- $\exists \alpha > 0 \text{ opt}_2(f(x)) \leq \alpha \text{ opt}_1(x)$;
- $\exists \beta > 0 \forall s \in F_2(f(x)) \mid \text{opt}_1(x) - c_1(g(s)) \mid \leq \beta \mid \text{opt}_2(f(x)) - c_2(s) \mid$

Definicja

Niech Π_1 i Π_2 będą problemami optymalizacyjnymi z kosztami odpowiednio c_1 i c_2 . Para funkcji f i g tworzy **L-redukcję** jeżeli zachodzą następujące warunki:

- f i g są obliczalne w czasie wielomianowym;
- $x \in D_1 \implies f(x) \in D_2$;
- $s \in F_2(f(x)) \implies g(s) \in F_1(x)$;
- $\exists \alpha > 0 \text{ opt}_2(f(x)) \leq \alpha \text{ opt}_1(x)$;
- $\exists \beta > 0 \forall s \in F_2(f(x)) \mid \text{opt}_1(x) - c_1(g(s)) \mid \leq \beta \mid \text{opt}_2(f(x)) - c_2(s) \mid$

Definicja

MaxSNP to klasa problemów optymalizacyjnych L-redukowalnych do problemów z **MaxSNP₀**.

Przykład (MAX CUT)

MAX CUT \in **MaxSNP**₀ więc i MAX CUT \in **MaxSNP**:

$$\max_{S \subseteq V} |\{(v, w) : \{v, w\} \in E \wedge v \in S \wedge w \notin S\}|.$$

Przykład (MAX CUT)

MAX CUT $\in \mathbf{MaxSNP}_0$ więc i MAX CUT $\in \mathbf{MaxSNP}$:

$$\max_{S \subseteq V} |\{(v, w) : \{v, w\} \in E \wedge v \in S \wedge w \notin S\}|.$$

Twierdzenie

Jeżeli $\Pi \in \mathbf{MaxSNP}_0$ jest postaci $\max_S |\{(x_1, \dots, x_k) : \phi\}|$, to istnieje dla Π algorytm $(1 - 2^{-k})$ -aproxymacyjny, gdzie k jest liczbą tych formuł atomowych w formule ϕ , które zawierają S .

MaxSNP-zupełność

Definicja

Problem $\Pi \in \mathbf{MaxSNP}$ jest **MaxSNP**-zupełny, jeżeli dowolny problem z **MaxSNP** L-redukuje się do niego.

MaxSNP-zupełność

Definicja

Problem $\Pi \in \text{MaxSNP}$ jest **MaxSNP**-zupełny, jeżeli dowolny problem z **MaxSNP** L-redukuje się do niego.

Fakt

MAX CUT *jest* **MaxSNP**-zupełny.

MaxSNP-zupełność

Definicja

Problem $\Pi \in \mathbf{MaxSNP}$ jest **MaxSNP**-zupełny, jeżeli dowolny problem z **MaxSNP** L-redukuje się do niego.

Fakt

MAX CUT *jest* **MaxSNP**-zupełny.

Problem

MaxSNP-zupełność

Definicja

Problem $\Pi \in \mathbf{MaxSNP}$ jest **MaxSNP**-zupełny, jeżeli dowolny problem z **MaxSNP** L-redukuje się do niego.

Fakt

MAX CUT jest **MaxSNP**-zupełny.

Problem

Wejście: ϕ — formuła logiczna z co najwyżej 3 zmiennymi na klauzulę

MaxSNP-zupełność

Definicja

Problem $\Pi \in \mathbf{MaxSNP}$ jest **MaxSNP**-zupełny, jeżeli dowolny problem z **MaxSNP** L-redukuje się do niego.

Fakt

MAX CUT jest **MaxSNP**-zupełny.

Problem

Wejście: ϕ — formuła logiczna z co najwyżej 3 zmiennymi na klauzulę

Wyjście: T – wartościowanie zmiennych spełniające największą liczbę klauzul

MaxSNP-zupełność

Definicja

Problem $\Pi \in \mathbf{MaxSNP}$ jest **MaxSNP**-zupełny, jeżeli dowolny problem z **MaxSNP** L-redukuje się do niego.

Fakt

MAX CUT jest **MaxSNP**-zupełny.

Problem

Wejście: ϕ — formuła logiczna z co najwyżej 3 zmiennymi na klauzulę

Wyjście: T – wartościowanie zmiennych spełniające największą liczbę klauzul

Fakt

MAX3SAT jest **MaxSNP**-zupełny.

Twierdzenie

Jeżeli istnieje wielomianowy schemat aproksymacji dla MAX3SAT, to $P = NP$.

Nieaproxymowalność

Twierdzenie

Jeżeli istnieje wielomianowy schemat aproksymacji dla MAX3SAT, to $P = NP$.

Wniosek

*Żaden problem **MaxSNP**-zupełny nie może mieć wielomianowego schematu aproksymacji, chyba że $P = NP$.*